

Bike Sharing Report

Report per l'Esame di Fondamenti di Machine Learning

DAVIDE ZANNI

131946

Ingegneria Informatica
250960@studenti.unimore.it

Abstract

Il presente documento riporta lo sviluppo e i risultati ottenuti applicando diverse tecniche di regressione al dataset Bike Sharing.

Il dataset contiene il conteggio giornaliero del noleggio di biciclette per gli anni 2011 e 2012.

L'obiettivo principale consiste nel prevedere la quantità di biciclette noleggate da utenti registrati e non registrati nei vari giorni dell'anno. Inoltre, ci consente di comprendere come varia il noleggio nel corso dell'anno in relazione alle stagioni e alle condizioni meteorologiche.

1 Analisi del Dataset

L'analisi inizia con uno studio esplorativo del dataset, che mi permette di comprendere la varietà e la tipologia dei dati presenti. Il dataset contiene 16 features e 731 istanze, con ogni istanza corrispondente a un giorno specifico nei due anni (2011 e 2012) presi in considerazione. Le features sono tutte di valore numerico *'int'* o *'float'* ad eccezione della colonna contenente la data, che è di tipo *'object'*.

Si è verificato che il dataset non contenga valori nulli, il che è positivo poiché avrebbe richiesto la sostituzione con la media degli altri valori o l'eliminazione diretta.

1.1 Bilanciamento Dataset

Sono state eseguite verifiche sul bilanciamento del dataset. Si è notato che il dataset è bilanciato rispetto agli anni considerati.

Mentre dal punto di vista delle condizioni meteorologiche, si è notato che sono stati rilevati una maggior quantità di campioni in cui il tempo era sereno rispetto alle condizioni nuvolose e piovose. In particolare, le informazioni relative al tempo piovoso sono molto minori.

1.2 Visualizzazione Dati

Per la rappresentazione dei dati sono state create tre diversi tipi di distribuzione.

La prima descrive l'andamento del noleggio delle biciclette in base al mese e all'anno.(Figure 1).

Si è notato nell'anno 2012 un notevole incremento di utilizzo di biciclette rispetto all'anno precedente, in particolare nei mesi estivi.

La seconda rappresentazione fornisce una descrizione dell'utilizzo delle biciclette in base al tipo di giorno (lavorativo e non lavorativo) e ai mesi. (Figure 2).

Si è notato un maggior utilizzo di biciclette durante le giornate lavorative.

Unica eccezione si verifica nei mesi di Maggio, Giugno e Settembre, durante i quali le condizioni meteorologiche piovose sono più rare.




Figure 1




Figure 2

Come ultima rappresentazione è rappresentato l'utilizzo delle biciclette in base alle diverse condizioni meteorologiche (Figure 3).

Si è notato un maggiore noleggio di biciclette durante le giornate serene, mentre il noleggio rimane stabile nei giorni nuvolosi.

Tuttavia, durante le giornate piovose, si è verificata una drastica diminuzione del noleggio, con un picco anomalo rilevato solo una volta durante il mese di luglio, il che lo rende un dato non affidabile.

Queste rappresentazioni ci permettono di avere una visione generale del comportamento del noleggio delle biciclette in base alle diverse condizioni temporali e meteorologiche nel dataset.

2 PreProcessing

La fase di Pre Processing è la fase in cui si organizzano e preparano i dati utili per la fase di addestramento dei modelli.

È fondamentale in quanto effettua la selezione di features importanti e significative e applica necessarie trasformazioni sui dati.

2.1 Matrice di Correlazione e Cleaning Data

Prima della selezione delle features, si analizzano i dati in modo da decidere quali colonne scartare. In questo contesto le colonne ritenute non rilevanti per l'addestramento dei modelli includono l'indice delle istanze e la colonna di tipo *object* relativa alla data del rilevamento.

Successivamente, viene rappresentata la matrice di correlazione, matrice utile per evidenziare le features altamente correlate tra di loro e quelle con una correlazione significativa rispetto alla variabile target.




Figure 3

Dalla matrice, è stato osservato che le features *temp* e *atemp* sono molto correlate fra di loro con un valore di correlazione pari a 0.99. Di conseguenza si decide di non considerare una delle due features (nel nostro caso *atemp*) in modo da evitare un sovradimensionamento del modello. Mantenere entrambe le features avrebbe introdotto informazioni duplicate e aumentato il rischio di overfitting.

Inoltre, non vengono considerate anche le features *casual* e *registered* in quanto ritenute troppo correlate con la variabile target. Poichè la somma delle due variabili corrisponde alla variabile che si vuole predire, includerle tutte avrebbe portato a una predizione perfetta.

Questa decisione è stata presa dopo una serie di tentativi effettuati sul modello di *Linear Regression*, in quanto il modello è in grado predire i risultati grazie a una semplice funzione lineare, senza commettere errori significativi.

2.2 Feature Selection

2.2.1 Suddivisione Dataset

Dopo aver determinato le features da includere per l'addestramento dei modelli. Il dataset viene suddiviso in Training Set e Testing Set, viene deciso di assegnare 2/3 delle istanze totali al set di Training (ossia 487 istanze) e il restante 1/3 al set di Test (244 istanze) per valutare le prestazioni dei modelli.

2.2.2 Standardizzazione Dati

Dopo la fase di analisi del dataset, si può notare che le features sono distribuite su intervalli molto diversi.

Per questo motivo, è stata applicata la standardizzazione (*StandardScaler()*) per ricondurre tutte le features allo stesso intervallo.

2.2.3 Regularizzazione

In questa fase, è stato applicato un modello di regolarizzazione definito come (*Lasso Regression*) per selezionare le features più importanti del Dataset.

Queste features sono state selezionate assegnando un coefficiente di importanza a ciascuna. Questi coefficienti di importanza determinano quali feature sono più importanti e informative.

Prima di applicare la regolarizzazione, è stata eseguita la standardizzazione dei dati per semplificare il processo di distribuzione dei pesi, in quanto le features si trovano nello stesso intervallo.

3 Model Selection e Training

3.1 Modelli

Model Selection è la fase in cui vengono selezionati i modelli che saranno poi addestrati per determinare quale sia il migliore per risolvere il problema di regressione preso in considerazione.

Per questo problema di regressione vengono selezionati i modelli di:

3.1.1 Linear Regression

Linear Regression è un modello di regressione standard, crea una relazione lineare tra le feature in ingresso e la variabile target.

3.1.2 K-Nearest Neighbors

K-Nearest Neighbors, modello non parametrico, funziona calcolando la media dei valori di output delle istanze più vicine nel training set. È scelto per questo problema in quanto consente di ottimizzare iperparametri, attraverso GridSearch. I parametri considerati includono il numero ottimo di vicini e il modo in cui considerare i vicini (ossia, se considerare i vicini tutti con lo stesso peso o assegnare loro un peso in base alla distanza).

3.1.3 Decision Tree

Decision Tree, modello non parametrico, scelto come nel caso del K-Nearest Neighbors in quanto ha iperparametri da ottimizzare durante la procedura di GridSearch. In questo caso, i parametri considerati includono la profondità del albero e il minimo numero di valori richiesti per continuare a dividere un nodo o una foglia dell'albero.

3.1.4 Support Vector Regressor

Support Vector Regressor, modello non parametrico, scelto in quanto utilizza due iperparametri per l'ottimizzazione dell'errore di training. Gli iperparametri sono C e ϵ , il primo, quando impostato su valori elevati, permette di penalizzare maggiormente l'errore di training consentendo un miglior adattamento ai dati di addestramento. Il secondo, considera la tolleranza consentita per gli errori di training.

3.2 Analisi GridSearch

In questa fase, per ciascun modello, si esegue una *GridSearch* per individuare i migliori iperparametri al fine di ottimizzare l'errore. Questo processo sfrutta la Cross-Validation K-Fold per valutare le prestazioni dei modelli in diverse configurazioni.

Una volta individuati i migliori iperparametri, questi vengono salvati e impostati all'interno di ciascun modello.

Questa procedura aiuta a identificare i modelli con le migliori configurazioni di iperparametri, consentendo di avere le migliori prestazioni sui dati di test.

3.3 Model Selection

In questa fase, i modelli vengono valutati per determinare quale modello ha le prestazioni migliori. Per ogni modello, effettua una Cross-Validation K-Fold e stima l'errore assoluto medio (MAE).

Successivamente, stampa il nome del modello insieme al corrispettivo errore calcolato al fine di poter confrontare i modelli e valutare quale sia più adatto per il problema.

In base alle prestazioni di errore, il modello Support Vector Regressor si è rivelato il migliore, con un errore di 507.5.

Tabella Performance Model Selection

Modello	MAE
Linear Regression	672.9
K-Nearest Neighbors	680.0
Decision Tree	668.4
Support Vector Regressor	507.5

3.4 Training

In questa fase, i modelli vengono addestrati in modo da essere pronti a effettuare previsioni sul Test Set.

I modelli non sono stati scartati durante la fase di Model Selection, ma verranno testati ulteriormente per ottenere una più completa rappresentazione grafica e dati per una comparazione più approfondita

4 Testing

Nella fase di testing, le prestazioni dei modelli vengono valutate utilizzando il Testing Set.

Per misurare l'efficacia, i modelli sono valutati utilizzando quattro metriche di regressione:

- Mean Squared Error (MSE): Media dei quadrati degli errori tra valori predetti dal modello e valori effettivi del test.
- Mean Absolute Error (MAE): Media dei valori assoluti degli errori tra valore predetto e valore effettivo del test.
- Root Mean Squared Error (RMSE): Radice quadrata di MSE,
- R-squared: Con valori compresi tra 0 e 1, rappresenta quanto bene il modello si adatta ai dati.

Le prestazioni vengono valutate in base a queste metriche, il che consente di confrontare le prestazioni dei diversi modelli tra di loro.

Un errore più basso di MAE, MSE e RMSE e un R-squared più alto indicano un modello migliore.

Le prestazioni di ciascun modello vengono rappresentate in grafici, per consentire un confronto visivo e identificare eventuali comportamenti anomali.(Figure 4)




Figure 4

Nel contesto, è importante notare che, considerando l'ordine di grandezza della variabile target (cnt), è accettabile avere un valore di errore dell'ordine delle centinaia. In quanto, l'ordine di grandezza della variabile target è dell'ordine delle migliaia.

5 Ensemble

Dopo aver testato i modelli e valutato le loro prestazioni, si decide di svolgere un'ulteriore valutazione utilizzando la tecnica *ensemble* denominata *Stacking Regressor*, al fine di migliorare le prestazioni combinando i quattro modelli utilizzati precedentemente.

I modelli di base selezionati sono: Linear Regression, K-Nearest Neighbors, Decision Tree e Support Vector Regressor. Il modello finale che combina le previsioni dei modelli è Linear Regression scelto in quanto più semplice, non avendo iperparametri da ottimizzare e con buone prestazioni precedentemente ottenute. Inoltre viene utilizzata la tecnica Cross-Validation K-Fold.

Successivamente, il modello viene addestrato e le sue prestazioni vengono valutate utilizzando le stesse metriche utilizzate in precedenza per gli altri modelli.

Infine, viene creato un grafico per visualizzare l'errore e confrontarlo con i grafici ottenuti in precedenza. (Figura 5)




Figure 5

6 Conclusioni

In conclusione dopo aver valutato le prestazioni dei modelli e della tecnica di ensemble.

In termini di errore assoluto medio e R-squared, il modello Support Vector Regressor sembra essere il migliore rispetto agli altri modelli. In quanto presenta un MAE di circa 418.7, inferiore rispetto agli altri modelli, e un R-squared di 0.913, più elevato rispetto agli altri.

Questo valore può essere favorito grazie ai parametri del modello, in particolare un valore elevato di C pari a 2000 e un epsilon di 0.5, che sono superiori ai valori predefiniti (C=1 e epsilon=0.1).

D'altra parte, Linear Regression produce risultati accettabili ma inferiori rispetto agli altri modelli implementati. Presenta un MAE alto di 637.0 e un R-Squared di 0.815, suggerendo che le previsioni potrebbero variare significativamente rispetto agli altri modelli considerati.

È stata valutata anche la tecnica di ensemble utilizzando il modello Stacking Regressor, il quale combina le prestazioni dei modelli precedenti. Ha ottenuto prestazioni simili a quelle del Support Vector Regressor in termini di R-squared ma con un MAE simile ma inferiore pari a 407.9.

In sintesi, la tecnica di ensemble si è dimostrata molto efficace nel migliorare le prestazioni complessive dei modelli. Tuttavia, il modello Support Vector Regressor è emerso come il migliore, offrendo previsioni più accurate con un errore minore.

Tabella Performance finali

Modello	MAE	MSE	RMSE	R-Squared
Linear Regression	637.0	714319.2	845.1	0.815
K-Nearest Neighbors	571.7	612696.9	782.7	0.841
Decision Tree	529.5	599171.5	774.0	0.845
Support Vector Regressor	418.7	334871.6	578.6	0.913
Stacking Regressor	407.9	333868.2	577.8	0.913